

# Les Réseaux de Neurones

Philibert PAPPENS, Tristan POIDATZ, Mathurin PETIT

2021-2022

# Contents

<b>1 Définitions</b>	<b>1</b>
1.1 Neurone . . . . .	1
1.2 Réseau de Neurones . . . . .	1
1.3 Fonction d'activation . . . . .	1
<b>2 Notations</b>	<b>2</b>
2.1 Poids . . . . .	2
2.2 Activation intermédiaire . . . . .	2
2.3 Biais . . . . .	2
2.4 Fonction d'activation . . . . .	2
2.5 Activation . . . . .	2
2.6 Matrice d'activation . . . . .	3
2.7 Matrice d'activations intermédiaires . . . . .	3
2.8 Matrice des poids . . . . .	3
2.9 Matrice gradient . . . . .	3
2.10 Matrice $\delta$ . . . . .	3
2.11 Produit de Hadamard . . . . .	3
<b>3 Formules de propagation</b>	<b>3</b>
3.1 Propagation avant . . . . .	3
3.2 Propagation arrière . . . . .	4
<b>4 Descente de gradient</b>	<b>5</b>
4.1 Principe . . . . .	5

## 1 Définitions

### 1.1 Neurone

Un Neurone est une représentation mathématique et informatique d'un neurone biologique. Il contient en général plusieurs entrées et une seule sortie. Mathématiquement, un neurone est une fonction à plusieurs variables et à valeurs réelles.

### 1.2 Réseau de Neurones

Un réseau de Neurones est une association de neurones pour accomplir des tâches arbitrairement complexes.

### 1.3 Fonction d'activation

Une fonction d'activation (souvent notée  $\sigma$ ) est une fonction de  $\mathbb{R}^{\mathbb{R}}$  dont son calcul et celui de sa dérivée est peu couteux en temps. Choisir des fonctions d'activations non-linéaires permet au réseau de créer des comportements plus complexes.

## 2 Notations

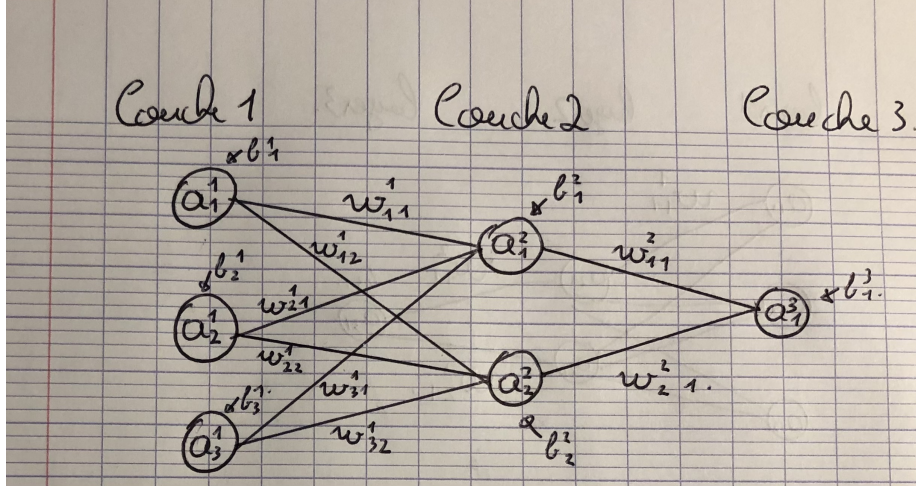


Figure 1: Réseau simple à trois couches

### 2.1 Poids

$$w_{i,j}^{\ell}$$

est le poids reliant le neurone  $i$  de la couche  $\ell$  au neurone  $j$  de la couche  $\ell + 1$

### 2.2 Activation intermédiaire

Considérons une couche  $\ell \in \mathbb{N}$  d'un réseau. Notons  $n$  le nombre de neurones dans la couche  $\ell$ . Pour le neurone  $i$  de la couche  $\ell + 1$ , on définit sa valeur d'activation intermédiaire:

$$z_i^{\ell+1} = \sum_{k=1}^n w_{k,i}^{\ell} a_k^{\ell} \quad (1)$$

### 2.3 Biais

$$b_i^{\ell}$$

est la valeur du biais  $i$  de la couche  $\ell$ .

### 2.4 Fonction d'activation

$$\sigma^{\ell} :$$

est la fonction d'activation permettant de passer de la couche  $\ell - 1$  à la couche  $\ell$ .

### 2.5 Activation

$$a_i^{\ell}$$

est la valeur du neurone  $i$  de la couche  $\ell$ . Elle vaut  $\sigma(z_i^{\ell})$

## 2.6 Matrice d'activation

$$A_\ell = (a_1^\ell \quad a_2^\ell \quad \dots \quad a_n^\ell)$$

## 2.7 Matrice d'activations intermédiaires

$$Z_\ell = (z_1^\ell \quad z_2^\ell \quad \dots \quad z_n^\ell)$$

## 2.8 Matrice des poids

$$W_\ell = \begin{pmatrix} w_{1,1}^\ell & w_{1,2}^\ell & \dots & w_{1,k}^\ell \\ w_{2,1}^\ell & w_{2,2}^\ell & \dots & w_{2,k}^\ell \\ \dots & \dots & \dots & \dots \\ w_{n,1}^\ell & w_{n,2}^\ell & \dots & w_{n,k}^\ell \end{pmatrix}$$

Où  $n$  est le nombre de neurones dans la couche  $\ell$  et  $k$  dans la couche  $\ell + 1$

## 2.9 Matrice gradient

Pour une matrice  $M_\ell$ , on note  $\nabla_M^\ell$  la matrice des dérivées partielles par rapport à chacun des coefficients. Par exemple:

$$\nabla_A^\ell = \begin{pmatrix} \frac{\partial}{\partial a_1^\ell} & \frac{\partial}{\partial a_2^\ell} & \dots & \frac{\partial}{\partial a_n^\ell} \end{pmatrix}$$

## 2.10 Matrice $\delta$

On pose  $\delta^\ell = \nabla_Z^\ell C$

## 2.11 Produit de Hadamard

L'opérateur  $\odot$  permet de définir le produit de Hadamard: le produit matriciel terme à terme:

$$\begin{pmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{pmatrix} \odot \begin{pmatrix} b_{1,1} & b_{1,2} \\ b_{2,1} & b_{2,2} \end{pmatrix} = \begin{pmatrix} a_{1,1} \cdot b_{1,1} & a_{1,2} \cdot b_{1,2} \\ a_{2,1} \cdot b_{2,1} & a_{2,2} \cdot b_{2,2} \end{pmatrix}$$

# 3 Formules de propagation

## 3.1 Propagation avant

L'équation (1) et la définition de  $Z_\ell$  peuvent être mises sous forme matricielle pour donner:

$$Z_{\ell+1} = A_\ell \cdot W_\ell + B_{\ell+1} \tag{2}$$

$$A_{\ell+1} = \sigma(Z_{\ell+1}) \tag{3}$$

### 3.2 Propagation arrière

Par le théorème de dérivation des fonctions composées, on a:

$$\frac{\partial C}{\partial z_j^\ell} = \frac{\partial C}{\partial a_j^\ell} \cdot \frac{\partial a_j^\ell}{\partial z_j^\ell} = \frac{\partial C}{\partial a_j^\ell} \sigma'(z_j^\ell)$$

Ce qui permet d'obtenir une première equation de rétro-propagation:

$$\delta^\ell = \nabla_a^\ell C \odot \sigma'(Z_\ell) \quad (4)$$

Puis,

$$\nabla_a^\ell C = \delta^{\ell+1} \cdot (W_\ell)^T \quad (5)$$

Les equations (4) et (5) permettent d'établir une relation de récurrence descendante sur la suite  $(\delta^\ell)_{\ell \in \mathbb{N}}$ :

$$\delta^\ell = (\delta^{\ell+1} \cdot (W_\ell)^T) \odot \sigma'(Z_\ell) \quad (6)$$

En appliquant une seconde fois ce théorème, on effectue le calcul matriciel suivant:

$$\begin{aligned} \nabla_w^\ell C &= \begin{pmatrix} \frac{\partial C}{\partial w_{1,1}^\ell} & \frac{\partial C}{\partial w_{1,2}^\ell} & \cdots & \frac{\partial C}{\partial w_{1,k}^\ell} \\ \frac{\partial C}{\partial w_{2,1}^\ell} & \frac{\partial C}{\partial w_{2,2}^\ell} & \cdots & \frac{\partial C}{\partial w_{2,k}^\ell} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial C}{\partial w_{n,1}^\ell} & \frac{\partial C}{\partial w_{n,2}^\ell} & \cdots & \frac{\partial C}{\partial w_{n,k}^\ell} \end{pmatrix} \\ &= \begin{pmatrix} \frac{\partial C}{\partial z_1^{\ell+1}} \cdot \frac{\partial z_1^{\ell+1}}{\partial w_{1,1}^\ell} & \frac{\partial C}{\partial z_2^{\ell+1}} \cdot \frac{\partial z_2^{\ell+1}}{\partial w_{1,2}^\ell} & \cdots & \frac{\partial C}{\partial z_k^{\ell+1}} \cdot \frac{\partial z_k^{\ell+1}}{\partial w_{1,k}^\ell} \\ \frac{\partial C}{\partial z_1^{\ell+1}} \cdot \frac{\partial z_1^{\ell+1}}{\partial w_{2,1}^\ell} & \frac{\partial C}{\partial z_2^{\ell+1}} \cdot \frac{\partial z_2^{\ell+1}}{\partial w_{2,2}^\ell} & \cdots & \frac{\partial C}{\partial z_k^{\ell+1}} \cdot \frac{\partial z_k^{\ell+1}}{\partial w_{2,k}^\ell} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial C}{\partial z_1^{\ell+1}} \cdot \frac{\partial z_1^{\ell+1}}{\partial w_{n,1}^\ell} & \frac{\partial C}{\partial z_2^{\ell+1}} \cdot \frac{\partial z_2^{\ell+1}}{\partial w_{n,2}^\ell} & \cdots & \frac{\partial C}{\partial z_k^{\ell+1}} \cdot \frac{\partial z_k^{\ell+1}}{\partial w_{n,k}^\ell} \end{pmatrix} \\ &= \begin{pmatrix} \nabla_z^{\ell+1} C \cdot a_1^\ell \\ \nabla_z^{\ell+1} C \cdot a_2^\ell \\ \vdots \\ \nabla_z^{\ell+1} C \cdot a_n^\ell \end{pmatrix} \\ &= \begin{pmatrix} \delta^{\ell+1} \cdot a_1^\ell \\ \delta^{\ell+1} \cdot a_2^\ell \\ \vdots \\ \delta^{\ell+1} \cdot a_n^\ell \end{pmatrix} \\ &= \begin{pmatrix} \delta^{\ell+1} \\ \delta^{\ell+1} \\ \vdots \\ \delta^{\ell+1} \end{pmatrix} \odot (A_\ell)^T \end{aligned}$$

On obtient ainsi:

$$\nabla_w^\ell C = \begin{pmatrix} \delta^{\ell+1} \\ \delta^{\ell+1} \\ \vdots \\ \delta^{\ell+1} \end{pmatrix} \odot (A_\ell)^T \quad (7)$$

Par un calcul analogue, on obtient:

$$\nabla_b^\ell C = \delta^\ell \quad (8)$$

## 4 Descente de gradient

### 4.1 Principe